## Análisis y Reporte sobre el desempeño del modelo.

## Maximiliano Martinez Marquez A01251527

```
In [3]:
from google.colab import drive
drive.mount("/content/gdrive")
!pwd # show current path
Drive already mounted at /content/gdrive; to attempt to forcibly remount,
call drive.mount("/content/gdrive", force remount=True).
/content
                                                                    In [4]:
%cd "/content/gdrive/MyDrive/AD2022"
!ls # show current directory
/content/gdrive/MyDrive/AD2022
Datos Titanic.README iris.data
                                  PlayDataset.csv wine.data
ds salaries.csv
                     iris.names test.csv
                                                  wine.names
gender submission.csv mercurio.csv train.csv
winequality red.csv
                                                                    In [5]:
!pip install mlxtend --upgrade --no-deps
Looking in indexes: https://pypi.org/simple, https://us-
python.pkg.dev/colab-wheels/public/simple/
Requirement already satisfied: mlxtend in /usr/local/lib/python3.7/dist-
packages (0.14.0)
Collecting mlxtend
  Downloading mlxtend-0.20.0-py2.py3-none-any.whl (1.3 MB)
          | 1.3 MB 7.8 MB/s
Installing collected packages: mlxtend
  Attempting uninstall: mlxtend
    Found existing installation: mlxtend 0.14.0
    Uninstalling mlxtend-0.14.0:
      Successfully uninstalled mlxtend-0.14.0
Successfully installed mlxtend-0.20.0
                                                                   In [16]:
import numpy as np
import pandas as pd
from sklearn.model selection import train test split, learning curve,
GridSearchCV
from sklearn.linear model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn import metrics
from sklearn.metrics import roc curve
```

```
from matplotlib import pyplot as plt
from mlxtend.evaluate import bias variance decomp
                                                                          In [5]:
red wine = pd.read csv('winequality red.csv', header = 0)
y = red_wine['class']
X = red wine.drop('class', axis=1)
Separación y evaluación del modelo con un conjunto de prueba y un conjunto de validación
(Train/Test/Validation)
                                                                          In [6]:
, , ,
Split para obtener conjunto de prueba y de entrenamiento.
:Prueba: = (20\%)
X train, X test, y train, y test = train test split(X, y, test size=0.2,
random state=1)
Split para obtener conjunto de validación.
:Validación: = (20\%)
:Entrenamiento: = (60%)
X train, X val, y train, y val = train test split(X train, y train,
test size=0.25, random state=1)
                                                                          In [7]:
lr = LogisticRegression(random state=1)
```

## Comportamiento esperado de Regresión Logística:

- Sesgo alto
- Varianza baja

```
In []:
lr.fit(X_train, y_train)
In [14]:
print(f"{lr.score(X_train, y_train):.3f}")
0.749
In []:
print(f"{lr.score(X_val, y_val):.3f}")
0.709
```

Al realizar una comparación en los scores del set de entrenamiento y el set de validación, se puede decir que el modelo no está overfit ya que el valor score de entrenamiento no se encuentra muy alejado del valor de score del set de validación.

```
In[]:
#set up plotting area
```


```
plt.figure(0).clf()

#fit logistic regression model and plot ROC curve
y_pred = lr.predict(X_val)
fpr, tpr, _ = metrics.roc_curve(y_val, y_pred)
auc = round(metrics.roc_auc_score(y_val, y_pred), 4)
plt.plot(fpr,tpr,label="Logistic Regression, AUC="+str(auc))
plt.plot([0,1],[0,1],color="black",linestyle="--")

#add legend
plt.legend()
```

Out[]:

<matplotlib.legend.Legend at 0x7f198a35fc10>



El siguiente paso es encontrar el valor del sesgo y de variación del modelo.

Luego, para poder evaluar nuestro modelo, se comparó con otro modelo, Árbol de decisión.

```
In[]:
train_sizes, train_scores, valid_scores = learning_curve(
    lr, X_train, y_train
)

train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)

valid_mean = np.mean(valid_scores, axis=1)

valid_std = np.std(valid_scores, axis=1)


In [11]:
plt.subplots(1, figsize=(10,10))
```

```
plt.plot(train_sizes, train_mean, '--', color="#111111", label="Training
score")
plt.plot(train_sizes, valid_mean, color="#111111", label="Cross-
Validation score")

plt.fill_between(train_sizes, train_mean - train_std, train_mean +
train_std, color="#DDDDDD")
plt.fill_between(train_sizes, valid_mean - valid_std, valid_mean +
valid_std, color="#DDDDDD")

plt.title("Learning Curve")
plt.xlabel("Training Set Size"), plt.ylabel("Accuracy Score"),
plt.legend(loc="best")
plt.tight_layout()
plt.show

Out[11]:
<function matplotlib.pyplot.show(*args, **kw)>
```



A partir de la curva de aprendizaje anterior, se puede observar que que modelo cuenta con underfitting y tambien se observa que despues al llegar a la mitad de los datos, la precisión disminuye.

```
In []:
X train v = X train.values
y train v = y train.values
X val v = X val.values
y_val_v = y_val.values
avg expected loss lr, avg bias lr, avg var lr = bias variance decomp(
        lr, X train v, y train v, X val v, y val v,
        loss='mse',
        random seed=1)
                                                                      In [15]:
print('Average expected loss: %.3f' % avg expected loss lr)
print('Average bias: %.3f' % avg_bias_lr)
print('Average variance: %.3f' % avg var lr)
Average expected loss: 0.288
Average bias: 0.251
Average variance: 0.036
```

A partir de los resultados anteriores, se puede observar que el sesgo es mucho mayor que la varianza, el cual se habia comentado que era el comportamiento esperado.

En el caso de Árbol de Decisión, se puede observar que el sesgo y la varianza se encuentran balanceados.

A partir de esto, y comparando con los valores de sesgo y varianza de regresión logística, se puede concluir, que el modelo cuenta con un sesgo entre alto y varianza baja.

Entonces, para reducir el sesgo se puede realizar una

```
'C' : np.logspace(-4, 4, 20),
    'solver' : ['lbfgs', 'newton-cg', 'liblinear', 'sag', 'saga'],
    'max iter' : [100, 1000,2500, 5000]
]
                                                                          In [27]:
new_lr = GridSearchCV(lr, param_grid = param_grid, cv = 3, verbose=True,
n jobs=-1)
                                                                            In []:
best lr = new lr.fit(X train, y train)
                                                                          In [34]:
best lr.best estimator .get params()
                                                                         Out[34]:
{'C': 0.23357214690901212,
'class weight': None,
 'dual': False,
 'fit intercept': True,
 'intercept scaling': 1,
 'll ratio': None,
 'max iter': 100,
 'multi class': 'auto',
 'n jobs': None,
 'penalty': '12',
 'random state': 1,
 'solver': 'newton-cg',
 'tol': 0.0001,
 'verbose': 0,
 'warm start': False}
                                                                          In [33]:
print(f"{best_lr.score(X_val, y_val):.3f}")
0.725
Ahora que está optimizado el modelo y se intentó arreglar el sesgo, se realizará una predicción
sobre el set de prueba.
```

print(f"{best lr.score(X test, y test):.3f}")

0.731

In [35]: